



四川大學
SICHUAN UNIVERSITY

机器学习-第十四章 非线性支持向量机

教师：胡俊杰 副教授

邮箱：hujunjie@scu.edu.cn

1.凸优化概述

■ 优化问题的一般形式

$$\text{minimize } f_0(x)$$

待优化的目标函数

$$\begin{array}{l} \text{subject to } f_i(x) \leq 0, i = 1, 2, \dots, m \\ \text{(s.t.)} \end{array}$$

m 个不等式约束

$$h_i(x) = 0, i = 1, 2, \dots, p$$

p 个等式约束

1.凸优化概述

- 凸集 (Convex set) : 如果连接集合 C 中任意两点的线段都在 C 内, 则 C 为凸集, 即

对于 $x_1, x_2 \in C$, 且 $0 \leq \theta \leq 1$

$$\theta x_1 + (1 - \theta)x_2 \in C$$

- 凸函数 (Convex function) : $\text{dom}f$ 是凸集, 对于所有 $x, y \in \text{dom}f$, 且 $0 \leq \theta \leq 1$, 以下不等式均成立

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$$

- 凸函数 vs 非凸函数

简单

复杂

1.凸优化概述

$$\text{minimize } f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0, i = 1, 2, \dots, m$$

$$h_i(x) = 0, i = 1, 2, \dots, p$$

凸优化

■ $\text{dom} f$ 是凸集, 目标函数 $f_0(x)$ 和不等式约束 $f_i(x)$ 为凸函数, 等式约束 $h_i(x)$ 为仿射函数, 凸优化的目标在于找到全局最优解 $x^* \in \text{dom} f$, 使得对任意 $x \in \text{dom} f$, $f(x^*) \leq f(x)$ 均成立

- 可行解 (feasible solution) : 满足所有约束条件的解
- 最优解 (optimal solution) : 满足所有约束条件, 且对任意 $x \in \text{dom} f$, $f(x^*) \leq f(x)$ 均成立

1.凸优化概述

$$\text{minimize } f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0, i = 1, 2, \dots, m$$

$$h_i(x) = 0, i = 1, 2, \dots, p$$

■ 拉格朗日函数

- 为每个约束指定一个拉格朗日乘子，以乘子为加权系数将约束增加到目标函数中

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$

$$L(x, \lambda, v): R^n \times R_+^m \times R^p \rightarrow R$$

$$x \in R^n \quad \lambda \in R_+^m, v \in R^p$$

1.凸优化概述

■ 拉格朗日函数

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$

$$\text{minimize } f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0, i = 1, 2, \dots, m$$

$$h_i(x) = 0, i = 1, 2, \dots, p$$

■ 拉格朗日对偶函数

- 对拉格朗日函数 $L(x, \lambda, v)$ 中的 x 取下确界可定义拉格朗日对偶函数

$$g(\lambda, v) = \inf_{x \in \mathbb{R}^n} L(x, \lambda, v) = \inf_{x \in \mathbb{R}^n} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \right)$$

- 拉格朗日对偶函数 $g(\lambda, v): \mathbb{R}_+^m \times \mathbb{R}^p \rightarrow \mathbb{R}$

inf (infimum): 下确界, 数学分析中的概念, 小于等于集合中的所有成员的最大实数

$$\inf\{x \in \mathbb{R}: 0 < x < 1\} = 0$$

sup (supremum): 上确界, 大于等于集合中所有成员的最小实数

$$\sup\{x \in \mathbb{R}: 0 < x < 1\} = 1$$

1.凸优化概述

■ 拉格朗日对偶函数

$$g(\lambda, v) = \inf_{x \in \mathbb{R}^n} L(x, \lambda, v) = \inf_{x \in \mathbb{R}^n} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \right)$$

- 拉格朗日对偶函数是凹函数，无论原问题是否为凸问题
- 拉格朗日对偶函数给出了原问题最优值的下界： $g(\lambda, v) \leq p^*$ ， p^* ：原问题 (primal problem) 的最优值 (optimal value)

1. 凸优化概述

■ 拉格朗日对偶函数

$$g(\lambda, v) = \inf_{x \in \mathbb{R}^n} L(x, \lambda, v) = \inf_{x \in \mathbb{R}^n} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \right)$$



从拉格朗日对偶函数获得的下界中，哪个是最优的？

当 $g(\lambda, v) = -\infty$ ，则其提供的下界无实际意义

■ 拉格朗日对偶问题

$$\max_{\lambda \geq 0, v} g(\lambda, v) = \max_{\lambda \geq 0, v} \inf_{x \in \mathbb{R}^n} L(x, \lambda, v)$$

- 假设拉格朗日对偶问题 (dual problem) 的最优值为 d^*

1.凸优化概述

■ 弱对偶

$$d^* \leq p^*$$

- 拉格朗日对偶函数给出了原问题最优值的下界: $g(\lambda, v) \leq p^*$
- 拉格朗日对偶问题: $\max_{\lambda \geq 0, v} g(\lambda, v)$

■ 强对偶

$$d^* = p^*$$

$$\text{minimize } f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0, i = 1, 2, \dots, m$$

$$h_i(x) = 0, i = 1, 2, \dots, p$$

- 如果 $f_0(x), \dots, f_m(x)$ 为凸函数, 通常情况下强对偶成立
- 强对偶成立的一般条件: Slater条件

■ 对偶间隙

$$p^* - d^*$$

1.凸优化概述

$$\text{minimize } f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0, i = 1, 2, \dots, m$$

$$h_i(x) = 0, i = 1, 2, \dots, p$$

■ 拉格朗日函数

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$


■ KKT条件

x^* 和 (λ^*, v^*) 分别是原问题和对偶问题的最优解, 且对偶间隙为0, 则


$$\left\{ \begin{array}{ll} \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0 & \text{稳定性条件} \\ f_i(x^*) \leq 0, i = 1, \dots, m & \text{原始可行性条件} \\ h_i(x^*) = 0, i = 1, \dots, p & \text{原始可行性条件} \\ \lambda_i^* \geq 0, i = 1, \dots, m & \text{对偶可行性条件} \\ \lambda_i^* f_i(x^*) = 0, i = 1, \dots, m & \text{互补松弛条件} \end{array} \right.$$

- 当原问题为凸问题时, 且不等式约束为凸函数, 等式约束为仿射变换, 则KKT条件为**充要条件**, 且对偶间隙为0。即满足KKT条件的解为最优解, 最优解一定满足KKT条件

2.支持向量机概述



6



■ 红色的决策线对输入扰动更加鲁棒 (robust)


■ 神经网络也存在鲁棒性问题，典型代表：对抗样本

2.支持向量机概述

支持向量机 (Support Vector Machine, SVM)

是一类以监督学习方式对数据进行二分类的分类模型

- SVM核心思想是寻找一个分类超平面，使得样本点与超平面的距离最大化
- SVM也被称为最大间隔分类器 (Large Margin Classifier)
- 支持向量 (Support Vector)：距离超平面最近的点



2.支持向量机概述

背景知识

任意超平面可以用下面这个线性方程来描述：

$$w^T x + b = 0$$


二维空间点 (x, y) 到直线 $Ax + By + C = 0$ 的距离公式是：

$$\frac{|Ax + By + C|}{\sqrt{A^2 + B^2}}$$

扩展到 n 维空间后，点 $x = (x^{(1)}, x^{(2)} \dots x^{(n)})$ 到超平面

$$w^T x + b = 0 \text{ 的距离为: } \frac{|w^T x + b|}{\|w\|}$$

$$\text{其中 } \|w\| = \sqrt{w_1^2 + \dots w_n^2}$$



如图所示，根据支持向量的定义，假设支持向量到决策超平面的距离为 d ，其他点到决策超平面的距离大于 d

2.支持向量机概述

- 给定训练数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中


$$x_i \in R^n, y_i \in \{+1, -1\}, i = 1, 2, \dots, N$$

假设超平面 (w, b) 将线性可分数据集正确分类, 即对于 $(x_i, y_i) \in D$, 若 $y_i = +1$, 则 $w^T x_i + b > 0$; 若 $y_i = -1$, 则 $w^T x_i + b < 0$, 令

$$\begin{cases} w^T x_i + b \geq +1, y_i = +1 \\ w^T x_i + b \leq -1, y_i = -1 \end{cases}$$

- 将以上两个方程合并, 可得: $y_i(w^T x_i + b) \geq 1$


- $y_i(w^T x_i + b) \geq 1$ 为**约束条件**, 即要求决策超平面 (w, b) 将所有样本分类正确



2.支持向量机概述

- 支持向量到超平面的距离可以写为: $d = \frac{|w^T x + b|}{\|w\|} = \frac{1}{\|w\|}$
- 两类（正类和负类）支持向量到超平面的距离之和为 $\gamma = \frac{2}{\|w\|}$ ，也被称为“间隔”，即**优化目标**

$$\begin{aligned} & \max_{w,b} \frac{2}{\|w\|} \\ & s.t. y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, N \end{aligned}$$



2.支持向量机概述

$$\max_{w,b} \frac{2}{\|w\|}$$

$$s.t. y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, N$$



$$\min_{w,b} \frac{1}{2} \|w\|^2 \text{ 方便后续求导}$$

$$s.t. y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, N$$

■ 即支持向量机 (SVM) 的基本形式

3.支持向量机求解

原优化问题:

$$\min_{w,b} \frac{1}{2} \|w\|^2$$
$$s.t. y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, N$$

拉格朗日函数: $L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w^T x_i + b) + \sum_{i=1}^N \alpha_i$

- 线性可分SVM满足强对偶条件, 即 $d^* = p^*$, 原问题最优值等于对偶问题最优值
- 通过解对偶问题, 得到最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)$, 得到原问题的最优解 (w^*, b^*)

3.支持向量机求解

$$\text{求 } \min_{w,b} L(w, b, \alpha) \quad L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w^T x_i + b) + \sum_{i=1}^N \alpha_i$$

$$\frac{\partial}{\partial w} L(w, b, \alpha) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \quad \Rightarrow \quad w = \sum_{i=1}^N \alpha_i y_i x_i$$

$$\frac{\partial}{\partial b} L(w, b, \alpha) = - \sum_{i=1}^N \alpha_i y_i = 0 \quad \Rightarrow \quad \sum_{i=1}^N \alpha_i y_i = 0$$

3.支持向量机求解

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad \text{代入} \quad L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w^T x_i + b) + \sum_{i=1}^N \alpha_i$$

$$\begin{aligned} \min_{w, b} L(w, b, \alpha) &= \frac{1}{2} w^T w - \sum_{i=1}^N \alpha_i y_i (w^T x_i + b) + \sum_{i=1}^N \alpha_i \\ &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i y_i \left(\left(\sum_{j=1}^N \alpha_j y_j x_j \right) \cdot x_i + b \right) + \sum_{i=1}^N \alpha_i \\ &= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \end{aligned}$$

3.支持向量机求解

构建拉格朗日对偶问题

求 $\min_{w,b} L(w, b, \alpha)$ 对 α 的极大

$$\max_{\alpha} \min_{w,b} L(w, b, \alpha) = \max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$s.t. \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$

最小化



$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

3.支持向量机求解

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \quad \alpha_i \geq 0, i = 1, 2, \dots, N \end{aligned}$$

设 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)$ 为拉格朗日对偶问题最优解, 则原始问题最优解 w^* 和 b^* 如下

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

$$b^* = ?$$

■ KKT条件

x^* 和 (λ^*, v^*) 分别是原问题和对偶问题的最优解, 且强对偶成立, 则

$$\begin{cases} \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0 \\ f_i(x^*) \leq 0, i = 1, \dots, m \\ h_i(x^*) = 0, i = 1, \dots, p \\ \lambda_i^* \geq 0, i = 1, \dots, m \\ \lambda_i^* f_i(x^*) = 0, i = 1, \dots, m \end{cases}$$

$$\alpha_i^* (y_i (w^T x_i^* + b^*) - 1) = 0$$

3.支持向量机求解

■ KKT条件

x^* 和 (λ^*, v^*) 分别是原问题和对偶问题的最优解，且强对偶成立，则

$$\left\{ \begin{array}{l} \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0 \\ f_i(x^*) \leq 0, i = 1, \dots, m \\ h_i(x^*) = 0, i = 1, \dots, p \\ \lambda_i^* \geq 0, i = 1, \dots, m \\ \boxed{\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m} \end{array} \right.$$

$$\alpha_i^* (y_i (w^T x_i^* + b^*) - 1) = 0$$

至少存在一个 $\alpha_j^* > 0$ ，（反证法：若 α^* 均为0，则 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i = 0$ ，然而 $w^* = 0$ 不是原始优化问题的解），因此

$$y_j (w^{*T} x_j^* + b^*) - 1 = 0$$

将 $w^* = \sum_{i=1}^N \alpha_i y_i x_i$ 代入上式，并利用 $y_j^2 = 1$ 可得

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

3.支持向量机求解

线性可分支持向量机学习算法

第1步：根据原始优化问题，写出拉格朗日函数

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w^T x_i + b) + \sum_{i=1}^N \alpha_i$$

第2步：求 $\min_{w,b} L(w, b, \alpha)$ ，并代入 $L(w, b, \alpha)$

$$\min_{w,b} L(w, b, \alpha) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

第3步：求解拉格朗日对偶问题，即

$$\max_{\alpha} \min_{w,b} L(w, b, \alpha) = \max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad s.t. \sum_{i=1}^N \alpha_i y_i = 0$$
$$\alpha_i \geq 0, i = 1, 2, \dots, N$$

求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)$

第4步：根据KKT条件可得原优化问题最优解 w^* 和 b^*

$$w^* = \sum_{i=1}^N \alpha_i y_i x_i \quad b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

第5步：构建决策超平面以及分类决策函数

决策超平面： $w^{*T} x + b^* = 0$

决策函数： $f(x) = \text{sign}(w^{*T} x + b^*)$

本章目录


01 线性支持向量机

02 非线性支持向量机

03 序列最小优化算法




1.线性支持向量机




$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$s. t. y_i (w^T x_i + b) \geq 1, i = 1, 2, \dots, N$$

- 以上假设训练样本是线性可分的，即存在一个超平面将两类样本完全分开
- 然而现实情况很复杂（如标签错误），应允许支持向量机对部分样本出错



1.线性支持向量机



■ 允许一些样本不满足约束 $y_i(w^T x_i + b) \geq 1$

■ 在最大化间隔的同时，不满足约束的样本应尽可能少，目标如下


$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N l_{0/1}(y_i(w^T x_i + b) - 1)$$

● $C > 0$ 为人为指定的惩罚参数， $l_{0/1}$ 代表0/1损失函数

$$l_{0/1} = \begin{cases} 1, & \text{if } z < 0 \\ 0, & \text{otherwise} \end{cases}$$

● 常量 C 允许部分样本不满足约束 $y_i(w^T x_i + b) \geq 1$

1.线性支持向量机



$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N l_{0/1}(y_i(w^T x_i + b) - 1)$$

- $l_{0/1}$ 非凸、不连续，以上目标函数不易求解。用数学性质较好的 “代理损失函数” (surrogate loss function)，替代 $l_{0/1}$
- 常用代理损失函数：
 - hinge损失函数 (hinge loss) : $l_{hinge}(z) = \max(0, 1 - z)$
 - 指数损失函数 (exponential loss) : $l_{exp}(z) = e^{-z}$
 - 对率损失函数 (logistic loss) : $l_{log}(z) = \log(1 + e^{-z})$


1.线性支持向量机

■ 常用代理损失函数：


- hinge损失函数 (hinge loss) : $l_{\text{hinge}}(z) = \max(0, 1 - z)$
- 指数损失函数 (exponential loss) : $l_{\text{exp}}(z) = e^{-z}$
- 对率损失函数 (logistic loss) : $l_{\text{log}}(z) = \log(1 + e^{-z})$



hinge, 铰链



1.线性支持向量机



$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N l_{0/1}(y_i(w^T x_i + b) - 1)$$

$l_{hinge}(z) = \max(0, 1 - z)$ 代替 $l_{0/1}$

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i(w^T x_i + b))$$

$\xi_i = \max(0, 1 - y_i(w^T x_i + b))$
(/ksaɪ/)

$$\begin{aligned} \min_{w,b,\xi_i} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i = 1, 2, \dots, N \end{aligned}$$

优化目标及约束

1.线性支持向量机

$$\begin{aligned} \min_{w,b,\xi_i} & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t. } & y_i(w^T x_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i = 1, 2, \dots, N \end{aligned}$$

1. 写出拉格朗日函数 $L(w, b, \xi, \alpha, \mu)$

2. 求 $L(w, b, \xi, \alpha, \mu)$ 对 w, b, ξ 的极小, 并代入 $L(w, b, \xi, \alpha, \mu)$

1.线性支持向量机

$$\begin{aligned} \min_{w,b,\xi_i} & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t.} & y_i(w^T x_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i = 1, 2, \dots, N \end{aligned}$$

1. 写出拉格朗日函数 $L(w, b, \xi, \alpha, \mu)$

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i + \sum_{i=1}^N \alpha_i (1 - \xi_i - y_i(w^T x_i + b)) - \sum_{i=1}^N \mu_i \xi_i$$

其中 $\alpha_i \geq 0, \mu_i \geq 0$ 为拉格朗日乘子

2. 求 $L(w, b, \xi, \alpha, \mu)$ 对 w, b, ξ 的极小, 并代入 $L(w, b, \xi, \alpha, \mu)$

$$\frac{\partial}{\partial w} L(w, b, \xi, \alpha, \mu) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0$$

$$\frac{\partial}{\partial b} L(w, b, \xi, \alpha, \mu) = - \sum_{i=1}^N \alpha_i y_i = 0$$

$$\frac{\partial}{\partial \xi_i} L(w, b, \xi, \alpha, \mu) = C - \alpha_i - \mu_i = 0$$

代入拉格朗日函数, 得

$$\min_{w,b,\xi} L(w, b, \xi, \alpha, \mu) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$\text{s.t.} \sum_{i=1}^N \alpha_i y_i = 0$$

$$C - \alpha_i - \mu_i = 0$$

$$\alpha_i \geq 0$$

$$\mu_i \geq 0, i = 1, 2, \dots, N$$

1. 线性支持向量机

$$\begin{aligned} \min_{w, b, \xi_i} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i = 1, 2, \dots, N \end{aligned}$$

3. 拉格朗日对偶问题

$$\begin{aligned} \max_{\alpha} \min_{w, b, \xi} L(w, b, \xi, \alpha, \mu) &= \max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & \left. \begin{aligned} C - \alpha_i - \mu_i &= 0 \\ \alpha_i &\geq 0 \\ \mu_i &\geq 0, i = 1, 2, \dots, N \end{aligned} \right\} \text{消去} \mu_i \quad \left. \begin{aligned} C - \alpha_i &\geq 0 \\ \alpha_i &\geq 0 \end{aligned} \right\} \text{合并} \quad 0 \leq \alpha_i \leq C \end{aligned}$$

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, N \end{aligned}$$

1.线性支持向量机

线性支持向量机的拉格朗日对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, N \end{aligned}$$

C 为人为指定的
惩罚参数

线性可分支持向量机的拉格朗日对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i, i = 1, 2, \dots, N \end{aligned}$$

■ 设 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)$ 为拉格朗日对偶问题最优解，则原问题最优解 w^* 和 b^* 如下

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i \quad b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

由KKT中的互补松弛条件可得

1.线性支持向量机

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

$$\text{超平面: } w^{*T} x + b^* = 0$$

$$\longrightarrow \sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* = 0$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

$$\text{决策函数: } f(x) = \text{sign}(w^{*T} x + b^*)$$

$$\longrightarrow f(x) = \text{sign}\left(\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^*\right)$$

$$\text{其中 } b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

本章目录


01 线性支持向量机

02 非线性支持向量机


03 序列最小优化算法



3.非线性支持向量机




线性不可分




高维下可分

- 无法找到一个超平面将两类样本分开
- 解决思路：对输入 x 作用非线性变换 ϕ ，将 x 从原始空间映射至高维空间，使得 $\phi(x)$ 可分

3.非线性支持向量机



全连接神经网络



卷积神经网络 (CNN)

■ 随着层数增加，隐藏层的神经元数量增加

■ 随着层数增加，特征的通道数 (channel) 增加

■ 高维空间的特征具有更强的可分能力

■ 对于CNN而言，简单地提高特征的通道数即可有效提高性能

ResNet → Wide ResNet

3.非线性支持向量机

线性可分支持向量机

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$s.t. y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, N$$

拉格朗日对偶问题如下:

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$s.t. \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$

非线性支持向量机, 优化目标及约束如下:

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$s.t. y_i(w^T \phi(x_i) + b) \geq 1, i = 1, 2, \dots, N$$


拉格朗日对偶问题如下:

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\phi(x_i) \cdot \phi(x_j)) + \sum_{i=1}^N \alpha_i$$

$$s.t. \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

3.非线性支持向量机



3.非线性支持向量机

非线性支持向量机，优化目标及约束如下：

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$s. t. y_i (w^T \phi(x_i) + b) \geq 1, i = 1, 2, \dots, N$$

拉格朗日对偶问题如下：

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\phi(x_i) \cdot \phi(x_j)) + \sum_{i=1}^N \alpha_i$$

$$s. t. \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

- 直接定义非线性映射函数 ϕ 较困难
- 引入核函数 $K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$ ， x_i 与 x_j 在特征空间中的内积等于在原始输入空间通过函数 $K(x_i, x_j)$ 计算的结果，从而避开定义 ϕ

3.非线性支持向量机

非线性支持向量机，优化目标及约束如下：

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$s. t. y_i(w^T \phi(x_i) + b) \geq 1, i = 1, 2, \dots, N$$

拉格朗日对偶问题如下：

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\phi(x_i) \cdot \phi(x_j)) + \sum_{i=1}^N \alpha_i$$

$$s. t. \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

引入核函数后，拉格朗日对偶问题如下：

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) + \sum_{i=1}^N \alpha_i$$

$$s. t. \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

3.非线性支持向量机

线性可分支持向量机

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i \quad b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

$$\text{超平面: } \sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* = 0$$

$$\text{决策函数: } f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* \right)$$

非线性支持向量机

$$w^* = \sum_{i=1}^N \alpha_i^* y_i \phi(x_i) \quad b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i \phi(x_i) \cdot \phi(x_j)$$

$K(x_i, x_j)$

$$\text{超平面: } \sum_{i=1}^N \alpha_i^* y_i \phi(x) \cdot \phi(x_i) + b^* = 0$$

$K(x, x_i)$

$$\text{决策函数: } f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i \phi(x) \cdot \phi(x_i) + b^* \right)$$

$K(x, x_i)$

3.非线性支持向量机

常用核函数有：

线性核函数

$$K(x_i, x_j) = x_i^T x_j$$

多项式核函数

$$K(x_i, x_j) = (x_i^T x_j)^d \quad d \geq 1, \text{ 为多项式的次数}$$

高斯核函数

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right) \quad \sigma > 0, \text{ 为高斯核的带宽 (width) }$$

- 这三个常用的核函数中，只有高斯核函数需要调参 σ
- 核函数的选择依赖于经验

3.非线性支持向量机

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$$

$$w^* = \sum_{i=1}^N \alpha_i^* y_i \phi(x_i) \quad b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i \phi(x_i) \cdot \phi(x_j)$$


$K(x_i, x_j)$

超平面: $\sum_{i=1}^N \alpha_i^* y_i \phi(x) \cdot \phi(x_i) + b^* = 0$

$K(x, x_i)$

决策函数: $f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i \phi(x) \cdot \phi(x_i) + b^* \right)$

$K(x, x_i)$



- 深度神经网络本质是一个复杂的非线性函数 F , $F: x \rightarrow y$
- 通用（万能）逼近定理（Universal Approximation Theorem）：神经网络可以近似任意的复杂函数，并且可以达到任意近似精度

本章目录

01 线性支持向量机

02 非线性支持向量机

03 序列最小优化算法



3.序列最小优化算法

拉格朗日对偶问题:

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) + \sum_{i=1}^N \alpha_i$$

$$s.t. \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

■ 如何求解 α^* ?

■ 序列最小优化算法 (Sequential Minimal Optimization) : 每次选择 α_i 和 α_j , 并固定其他参数, 求 α_i 和 α_j 的极值, 直至收敛。求解思路如下:

- 选择一对需要更新的变量 α_i 和 α_j
- 固定 α_i 和 α_j 之外的参数, 求 ∇_{α_i} 和 ∇_{α_j}

■ SMO算法的两个主要部分:

- 求解两个变量 α_i 和 α_j 的解析方法
- 选择待优化变量 α_i 和 α_j 的方法

3.序列最小优化算法

■ 求解两个变量 α_i 和 α_j

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) + \sum_{i=1}^N \alpha_i$$

$$s.t. \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

- 记 $K_{ij} = K(x_i, x_j)$

- 选择 α_1 和 α_2 为待优化变量，其余视为常量

$$\begin{aligned} \min_{\alpha_1, \alpha_2} W(\alpha_1, \alpha_2) &= \frac{1}{2} K_{11} \alpha_1^2 + \frac{1}{2} K_{22} \alpha_2^2 + y_1 y_2 K_{12} \alpha_1 \alpha_2 \\ &\quad - (\alpha_1 + \alpha_2) + y_1 \alpha_1 \sum_{i=3}^N y_i \alpha_i K_{i1} + y_2 \alpha_2 \sum_{i=3}^N y_i \alpha_i K_{i2} \end{aligned}$$

$$s.t. \alpha_1 y_1 + \alpha_2 y_2 = - \sum_{i=3}^N y_i \alpha_i = \tau$$


$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

3.序列最小优化算法


$$\min_{\alpha_1, \alpha_2} W(\alpha_1, \alpha_2) = \frac{1}{2} K_{11} \alpha_1^2 + \frac{1}{2} K_{22} \alpha_2^2 + y_1 y_2 K_{12} \alpha_1 \alpha_2 - (\alpha_1 + \alpha_2) + y_1 \alpha_1 \sum_{i=3}^N y_i \alpha_i K_{i1} + y_2 \alpha_2 \sum_{i=3}^N y_i \alpha_i K_{i2}$$

$$s.t. \quad \alpha_1 y_1 + \alpha_2 y_2 = - \sum_{i=3}^N y_i \alpha_i = \tau$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$



• $y_1 \neq y_2, \alpha_2 - \alpha_1 = k$




• $y_1 = y_2, \alpha_1 + \alpha_2 = k$

■ 设初始可行解为 $\alpha_1^{old}, \alpha_2^{old}$, 最优解为 $\alpha_1^{new}, \alpha_2^{new}$

■ 设 α_2 未被截断 (clip) 的解为 $\alpha_2^{new, unc}$

3.序列最小优化算法



α_i 需满足以下等式和不等式约束

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$


● $y_1 \neq y_2, \alpha_1 - \alpha_2 = k$

$$y_1 \alpha_1 + y_2 \alpha_2 = \tau$$

$$L = \max(0, -k) = \max(0, \alpha_2^{old} - \alpha_1^{old})$$

$$L \leq \alpha_2^{new} \leq H$$

$$H = \min(C, C - k) = \min(C, C + \alpha_2^{old} - \alpha_1^{old})$$



● $y_1 = y_2, \alpha_1 + \alpha_2 = k$

$$L = \max(0, k - C) = \max(0, \alpha_1^{old} + \alpha_2^{old} - C)$$

$$H = \min(C, k) = \min(C, \alpha_1^{old} + \alpha_2^{old})$$

3.序列最小优化算法

- 1. 先求沿着约束方向未截断的解 $\alpha_2^{new,unc}$
- 2. 再根据上界 (H) 和下界 (L) 得到优化后的解 α_2^{new}

预测值 $g(x) = w^T \phi(x) + b = \sum_{i=1}^N \alpha_i y_i K(x_i, x) + b$

误差 $E_i = g(x_i) - y_i = \left(\sum_{i=1}^N \alpha_i y_i K(x_i, x) + b \right) - y_i$

3. 序列最小优化算法

- 1. 求沿着约束方向未截断的解 $\alpha_2^{new,unc}$

$$\alpha_2^{new,unc} = \alpha_2^{old} + \frac{y_2(E_1 - E_2)}{\eta}$$

$$\eta = K_{11} + K_{22} - 2K_{12}$$

具体推导参考教材

- 2. 根据上界 (H) 和下界 (L) 得到优化后的解 α_2^{new}

$$\alpha_2^{new} = \begin{cases} H, & \alpha_2^{new,unc} > H \\ \alpha_2^{new,unc}, & L \leq \alpha_2^{new,unc} \leq H \\ L, & \alpha_2^{new,unc} < L \end{cases}$$

$$\begin{cases} \alpha_1^{old} y_1 + \alpha_2^{old} y_2 = \tau \\ \alpha_1^{new} y_1 + \alpha_2^{new} y_2 = \tau \end{cases}$$

$$\alpha_1^{new} y_1 + \alpha_2^{new} y_2 = \alpha_1^{old} y_1 + \alpha_2^{old} y_2$$

$\downarrow y^2 = 1$

$$\alpha_1^{new} = \alpha_1^{old} + y_1 y_2 (\alpha_2^{old} - \alpha_2^{new})$$


3.序列最小优化算法

- 选择待优化变量 α_i 和 α_j , 包含两层循环
 - 外循环选择第一个变量
 - 内循环选择第二个变量
- SMO算法结束的条件: 所有 α_i 满足KKT条件
- KKT条件

x^* 和 (λ^*, v^*) 分别是原问题和对偶问题的最优解, 且强对偶成立, 则

$$\left\{ \begin{array}{l} \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0 \\ f_i(x^*) \leq 0, i = 1, \dots, m \\ h_i(x^*) = 0, i = 1, \dots, p \\ \lambda_i^* \geq 0, i = 1, \dots, m \\ \boxed{\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m} \end{array} \right. \quad \text{互补松弛条件}$$

- 当原问题为凸问题时, 且不等式约束为凸函数, 等式约束为仿射变换, 则KKT条件为**充要条件**, 且对偶间隙为0。即满足KKT条件的解为最优解, 最优解一定满足KKT条件



$$\begin{cases} w^T \phi(x_i) + b \geq +1, y_i = +1 \\ w^T \phi(x_i) + b \leq -1, y_i = -1 \end{cases}$$

- 将以上两个方程合并, 可得约束条件: $y_i(w^T \phi(x_i) + b) \geq 1$
- 即 $y_i g(x_i) \geq 1$

其中: $g(x_i) = w^T \phi(x_i) + b = \sum_{j=1}^N \alpha_j y_j K(x_i, x_j) + b$

3.序列最小优化算法

■ KKT条件

x^* 和 (λ^*, v^*) 分别是原问题和对偶问题的最优解，且强对偶成立，则

$$\begin{cases} \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0 \\ f_i(x^*) \leq 0, i = 1, \dots, m \\ h_i(x^*) = 0, i = 1, \dots, p \\ \lambda_i^* \geq 0, i = 1, \dots, m \\ \boxed{\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m} \end{cases}$$

互补松弛条件

■ SVM的约束条件

$$y_i g(x_i) \geq 1$$

■ 外循环：确定第1个变量，即选择违反KKT互补松弛条件最严重的样本，即：

$$0 < \alpha_i < C \leftrightarrow y_i g(x_i) = 1$$

$$\alpha_i = 0 \leftrightarrow y_i g(x_i) \geq 1$$

$$\alpha_i = C \leftrightarrow y_i g(x_i) \leq 1$$

$$\text{其中: } g(x_i) = w^T x_i + b = \sum_{j=1}^N \alpha_j y_j K(x_i, x_j) + b$$

■ 内循环：假设外循环已找到第1个变量 α_1 ，选择与 α_1 差别最大的样本，从而使得目标函数下降最快，可选择最大 $|E_1 - E_2|$ 对应的 α_2

谢 谢!

